

BLM308 Veri Madenciliđi Final Projesi

Çevrimiçi Alışveriş Ürün İade Tahmini

Emre Kaya

Öğrenci No: 231041045

BLM308 Veri Madenciliđi

Teslim: Mayıs 2026

İçindekiler

Öğrenci Bilgileri	2
Proje Görev Dağılımı	3
Özet	4
1 Problem Tanımı	5
2 Motivasyon ve İş Değeri	6
3 İlgili Çalışmalar / Literatür	7
4 CRISP-DM Metodolojisi	8
5 Veri Seti Kaynağı ve Açıklaması	9
6 Keşifsel Veri Analizi (EDA)	10
7 Ön İşleme Adımları	14
8 Seçilen Modeller	15
9 Değerlendirme Kurulumu	16
10 Performans Karşılaştırması	17
11 En İyi Model Sonuçları	18
12 Önyargı-Varyans Tartışması	22
13 İş Yorumu	23
14 Kısıtlamalar	24
15 Gelecek Çalışmalar	25

Öğrenci Bilgileri

- Ad Soyad: Emre Kaya
- Öğrenci Numarası: 231041045
- Ders: BLM308 Veri Madenciliği
- Teslim Tarihi: Mayıs 2026

Proje Görev Dağılımı

Bu proje bireysel olarak Emre Kaya tarafından gerçekleştirilmiştir. Veri ön işleme, keşifsel veri analizi, model eğitimi, değerlendirme, rapor ve sunum hazırlığının tamamı proje sahibi tarafından yapılmıştır.

Özet

Bu proje, bir e-ticaret siparişinin iade edilip edilmeyeceğini tahmin eden ikili sınıflandırma problemini ele almaktadır. `product_return_prediction.csv` veri seti (1.500 kayıt) kullanılarak CRISP-DM metodolojisi uygulanmış, keşifsel veri analizi gerçekleştirilmiş ve beş sınıflandırma algoritması eğitim kümesi üzerinde 10 katmanlı stratified çapraz doğrulama ile karşılaştırılmıştır. En iyi performansı gösteren model Random Forest olmuş; ayrılmış test kümesinde yalnızca bir kez değerlendirilmiş ve F1-skoru 0,2206, ROC-AUC değeri 0,4793 elde edilmiştir.

Bölüm 1

Problem Tanımı

Ürün iadeleri çevrimiçi perakendede operasyonel maliyet, stok yönetimi sorunları ve müşteri memnuniyetsizliği yaratmaktadır. Bu projenin amacı, **return_status** (0 = iade edilmedi, 1 = iade edildi) değişkenini tahmin ederek perakendecilerin kalite kontrolünü önceliklendirmesine, fiyatlandırma politikalarını düzenlemesine ve müşteri deneyimini iyileştirmesine yardımcı olmaktır.

Bölüm 2

Motivasyon ve İş Değeri

- Yüksek riskli siparişleri erken tespit ederek ters lojistik maliyetlerini azaltmak
- İade edilecek ürünleri öngörerek envanter planlamasını iyileştirmek
- Düşük puanlı alışverişlerde hedefli müşteri hizmeti sunmak
- Veriye dayalı fiyatlandırma ve ürün portföyü kararlarını desteklemek

Bölüm 3

İlgili Çalışmalar / Literatür

E-ticaret analitiğinde iade tahmini; müşteri davranışı, ürün özellikleri ve satın alma sonrası geri bildirimler kullanılarak incelenmiştir. Önceki çalışmalar, fiyat duyarlılığı, ürün kalitesi sinyalleri (puanlar) ve ürüne özgü kalıpların iadeler için güçlü öngörücüler olduğunu göstermektedir. Dengesiz perakende sınıflandırma görevlerinde ağaç tabanlı topluluk modelleri ve lojistik regresyon yaygın olarak kullanılan temel yöntemlerdir.

Bölüm 4

CRISP-DM Metodolojisi

1. **İş Anlayışı:** İade tahminini maliyet azaltma odaklı bir kullanım senaryosu olarak tanımlama
2. **Veri Anlayışı:** Şema, eksik değerler ve sınıf dengesizliğini inceleme
3. **Veri Hazırlığı:** Ürün encoding, ölçekleme, stratified bölünme
4. **Modelleme:** Decision Tree, Random Forest, Logistic Regression, Naive Bayes, KNN
5. **Değerlendirme:** Eğitim kümesinde 10 katmanlı stratified CV; test kümesi yalnızca final değerlendirme
6. **Dağıtım:** Perakende operasyonları için uygulanabilir içgörülerin dokümente edilmesi

Bölüm 5

Veri Seti Kaynağı ve Açıklaması

- **Dosya:** `product_return_prediction.csv`
- **Kayıt sayısı:** 1.500 gözlem, 5 sütun
- **Sütunlar:** `order_id`, `product_id`, `price`, `rating`, `return_status`
- **Hedef:** `return_status` (Sınıf 0: 1.094, Sınıf 1: 406)
- **Eksik değer:** Yok
- **Eksik sütunlar:** Kategori, indirim, teslimat süresi bulunmamaktadır


Bölüm 6

Keşifsel Veri Analizi (EDA)


Sınıf dağılımı, fiyat-iade ilişkisi, puan dağılımı ve korelasyon grafikleri oluşturulmuştur. Kategori, indirim ve teslimat süresi grafikleri veri setinde ilgili sütunlar olmadığı için atlanmıştır.




Şekil 6.1: Sınıf dağılımı (iade oranı $\approx$ %27)



Şekil 6.2: Fiyat ve iade durumu ilişkisi



Şekil 6.3: Müşteri puanı dağılımı



Şekil 6.4: Sayısal özellikler korelasyon ısı haritası

Bölüm 7

Ön İşleme Adımları

- `order_id` benzersiz tanımlayıcı olarak çıkarıldı
- `product_id` ordinal özellik olarak kullanılmadı; Label Encoding kaldırıldı
- `product_id_frequency`: her ürünün yalnızca eğitim kümesindeki görülme sayısı
- `product_return_rate`: ürün bazlı iade oranı yalnızca eğitim kümesinden hesaplandı
- Eğitimde görülmeyen 78 test ürünü için frekans=0, iade oranı=eğitim ortalaması (0,2708)
- `price`, `rating` ve türetilen özelliklere StandardScaler (yalnızca eğitimde fit)
- Stratified %80/%20 bölünme encoding öncesinde yapıldı (`random_state=42`)

Bölüm 8

Seçilen Modeller

- Decision Tree (Karar Ağacı) — `max_depth=8, min_samples_leaf=5`
- Random Forest (Rastgele Orman) — `n_estimators=200, max_depth=12`
- Logistic Regression (Lojistik Regresyon) — `max_iter=1000`
- Gaussian Naive Bayes
- K-Nearest Neighbors (KNN) — `n_neighbors=7`

Bölüm 9

Değerlendirme Kurulumu

Veri seti stratified %80/%20 oranında eğitim (1.200) ve test (300) kümelerine ayrılmıştır. `product_id` için frekans ve iade oranı özellikleri yalnızca eğitim kümesinden türetilmiştir. Çapraz doğrulama sırasında bu özellikler **her fold içinde yeniden hesaplanarak** target leakage önlenmiştir. Model karşılaştırması yalnızca eğitim kümesi üzerinde 10 katmanlı Stratified Cross Validation ile yapılmıştır. Test kümesi modele hiçbir aşamada dahil edilmemiş; yalnızca seçilen en iyi model tam eğitim kümesi ile eğitildikten sonra **bir kez** final değerlendirme için kullanılmıştır. Model seçim kriteri: çapraz doğrulama ortalama F1-skoru.

Bölüm 10

Performans Karşılaştırması

Aşağıdaki tablo yalnızca eğitim kümesi üzerindeki 10 katmanlı CV ortalamalarını göstermektedir.

Tablo 10.1: Model performans karşılaştırması (10-fold Stratified CV, eğitim kümesi)

Model	Doğruluk	Kesinlik	Duyarlılık	F1-Skoru	ROC-AUC
Random Forest	0,6717	0,3551	0,2734	0,3065	0,5333
Decision Tree	0,6275	0,2960	0,2733	0,2822	0,5172
Naive Bayes	0,6633	0,3303	0,2455	0,2791	0,5766
KNN	0,6692	0,3299	0,2269	0,2663	0,5199
Logistic Regression	0,6683	0,3270	0,2270	0,2646	0,5713

Bölüm 11

En İyi Model Sonuçları


Eğitim kümesi CV F1-skoruna göre seçilen en iyi model: **Random Forest**.

Seçilen model tam eğitim kümesi (1.200 kayıt) ile eğitilmiş ve test kümesi (300 kayıt) üzerinde yalnızca bir kez değerlendirilmiştir.


Tablo 11.1: Random Forest — bağımsız test kümesi metrikleri

Metrik	Değer
Doğruluk	0,6467
Kesinlik	0,2727
Duyarlılık	0,1852
F1-skoru	0,2206
ROC-AUC	0,4793


Confusion matrix (test): TN=179, FP=40, FN=66, TP=15.



Şekil 11.1: En iyi model için karmaşıklık matrisi (Random Forest, test kümesi)



Şekil 11.2: En iyi model için ROC eğrisi (test kümesi)



Şekil 11.3: Random Forest özellik önem dereceleri

Bölüm 12

Önyargı-Varyans Tartışması

Karar Ağacı modelleri daha yüksek varyansa sahip olabilir ve gürültülü kalıplara aşırı uyum gösterebilir. Random Forest varyansı azaltır ancak ürün düzeyindeki kalıpları ezberleyebilir. Lojistik Regresyon daha düşük varyans sunar fakat doğrusal olmayan etkileşimleri yakalayamayabilir. Seçilen model, genelleme ile tahmin performansı arasında denge kurmayı hedefler.

Bölüm 13

İş Yorumu

Düşük müşteri puanları ve ürün bazlı iade oranı sinyalleri önemli öngörücülerdir. Perakende ekipleri iade risk skorlarını proaktif destek, kalite incelemesi ve fiyatlandırma gözden geçirmesi için kullanabilir.

Bölüm 14

Kısıtlamalar

- Sınırlı özellik seti (demografi, kategori, indirim, teslimat yok)
- Sınıf dengesizliği azınlık sınıfının duyarlılığını olumsuz etkiler
- Test kümesinde 78 eğitimde görülmemiş ürün bulunmaktadır
- Sonuçlar geçmiş verilere dayanır; mevsimsel etkiler yansıtılamayabilir

Bölüm 15

Gelecek Çalışmalar

- Yorum metinleri, teslimat süresi ve promosyon verilerinin entegrasyonu
- SMOTE veya maliyet-duyarlı öğrenme ile sınıf dengesizliği yönetimi
- Ürün embedding yöntemleri
- Gerçek zamanlı skarlama API'si

Bölüm 16

Yapay Zeka Kullanım Beyanı

Proje yapılırken yapay zeka araçlarından yararlanılmıştır.

Kaynakça

- [1] Chapman, P. et al. (2000). *CRISP-DM 1.0 Step-by-step data mining guide*.
- [2] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [3] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python.