

BLM308 Veri Madenciliđi Final Projesi

Çevrimiçi Alışveriş Ürün İade Tahmini

Öğrenci Bilgileri

- Ad Soyad: Emre Kaya
- Öğrenci Numarası: 231041045
- Ders: BLM308 Veri Madenciliđi
- Teslim Tarihi: Mayıs 2026
- GitHub Deposu: <https://github.com/emrekayy/blm308-urun-iade-tahmini>

Proje Görev Dağılımı

- Bu proje bireysel olarak Emre Kaya tarafından gerçekleştirilmiştir. Tüm proje adımları proje sahibi tarafından yapılmıştır.

Özet

- Bu proje, 1500 kayıtlı product_return_prediction.csv veri seti ile e-ticaret ürün iadesi tahmin etmektedir. Beş sınıflandırıcı yalnızca eğitim kümesi üzerinde 10 katmanlı stratified çapraz doğrulama ile karşılaştırılmıştır. En iyi model: Random Forest. Test kümesi yalnızca bir kez final değerlendirme için kullanılmıştır (F1=0.2206, ROC-AUC=0.4793).

1. Problem Tanımı

- return_status (0 = iade yok, 1 = iade var) değişkenini tahmin ederek ters lojistik maliyetlerini azaltmak ve müşteri deneyimini iyileştirmek.

2. Motivasyon ve İş Değeri

- İade maliyetlerini düşürmek, envanter planlamasını iyileştirmek ve proaktif destek sağlamak.

3. İlgili Çalışmalar / Literatür

- E-ticaret çalışmaları fiyat, puan ve ürün özelliklerinin iade için güçlü öngörücüler olduğunu gösterir.

4. CRISP-DM Metodolojisi

- İş anlayışı, veri anlayışı, hazırlık, modelleme, değerlendirme ve dağıtım aşamaları uygulanmıştır.

5. Veri Seti Kaynağı ve Açıklaması

- Sütunlar: order_id, product_id, price, rating, return_status
- Hedef: return_status | Sınıf 0: 1094, Sınıf 1: 406
- Eksik değer yok. Kategori, indirim ve teslimat sütunları mevcut değil.

6. Keşifsel Veri Analizi

- Sınıf dağılımı, fiyat-iade, puan dağılımı ve korelasyon grafikleri oluşturuldu.
- Oluşturulmayan grafikler: Kategoriye göre iade oranı (kategori sütunu bulunamadı), İndirim ve iade ilişkisi (indirim sütunu bulunamadı), Teslimat süresi ve iade ilişkisi (teslimat süresi sütunu bulunamadı).

7. Ön İşleme Adımları

- order_id çıkarıldı; product_id ordinal olarak kodlanmadı.
- product_id_frequency ve product_return_rate eğitim kümesinden türetildi.
- Eğitimde görülmeyen ürünler için frekans=0, iade oranı=eğitim ortalaması.
- Scaler yalnızca eğitim kümesinde fit edildi; stratified bölünme encoding öncesinde yapıldı.

8. Seçilen Modeller

- Decision Tree, Random Forest, Logistic Regression, Naive Bayes, KNN.

9. Değerlendirme Kurulumu

- 10 katmanlı Stratified CV yalnızca eğitim kümesinde (1.200 kayıt).
- Ürün frekans/iade oranı encoding her CV fold içinde yeniden hesaplandı.
- Test kümesi (300 kayıt) yalnızca bir kez final değerlendirme için kullanıldı.
- Metrikler: Doğruluk, Kesinlik, Duyarlılık, F1, ROC-AUC. Model seçimi: CV F1-skoru.

10. Performans Karşılaştırması

Model	Doğruluk	Kesinlik	Duyarlılık	F1-Skoru	ROC-AUC
Random Forest	0.6717	0.3551	0.2734	0.3065	0.5333
Decision Tree	0.6275	0.2960	0.2733	0.2822	0.5172
Naive Bayes	0.6633	0.3303	0.2455	0.2791	0.5766
KNN	0.6692	0.3299	0.2269	0.2663	0.5199
Logistic Regression	0.6683	0.3270	0.2270	0.2646	0.5713

11. En İyi Model Sonuçları

- En iyi model (eđitim CV): Random Forest
- Model tam eđitim kümesi ile eđitildi; test kümesi bağımsız final deđerlendirme.
- Test Doğruluk=0.6467, Kesinlik=0.2727, Duyarlılık=0.1852, F1=0.2206, ROC-AUC=0.4793
- Confusion matrix: TN=179, FP=40, FN=66, TP=15

12. Önyargı-Varyans Tartışması

- Ağaç modelleri doğrusal olmayan kalıpları yakalar ancak aşırı uyum riski taşır. Doğrusal modeller daha iyi geneller fakat karmaşık etkileşimleri kaçırabilir.

13. İş Yorumu

- Puan ve ürün bazlı sinyaller proaktif destek ve kalite incelemesi için kullanılabilir.

14. Kısıtlamalar

- Sınırlı özellik seti, sınıf dengesizliği ve product_id genelleme kısıtları.

15. Gelecek Çalışmalar

- Yorum metni, teslimat özellikleri, dengesizlik yönetimi ve gerçek zamanlı dağıtım.

16. Kaynaklar

- Chapman et al. (2000) CRISP-DM; Breiman (2001) Random Forests; Pedregosa et al. (2011) scikit-learn.


Şekil 1: Sınıf dağılımı




Şekil 2: Fiyat ve iade durumu



Şekil 3: Karmaşıklık matrisi



Şekil 4: ROC eğrisi



Şekil 5: Random Forest özellik önem dereceleri

